

# 基于多传感器信息的汽车低速车速估计方法<sup>\*</sup>

浦震峰<sup>1</sup>, 唐亮<sup>1</sup>, 上官文斌<sup>2</sup>, 王伟玮<sup>3</sup>, 蒋开洪<sup>3</sup>

(1. 北京林业大学工学院, 北京 100083; 2. 华南理工大学机械与汽车工程学院, 广州 510621;  
3. 宁波拓普集团股份有限公司, 宁波 315800)

**[摘要]** 为解决低速工况下轮速传感器测量精度低、更新周期长的问题,利用现有的底盘域传感器的信号,本文提出了一种基于多传感器信号的电驱动汽车低速车速估计方法。为准确估计车速,建立了基于多轮速脉冲信号的车速估算模型(模型I)和基于电机转速信号的车速估算模型(模型II)。在估算轮速时,模型I可以有效地避免噪声干扰,但在极低速的情况下,其更新周期较长;而模型II估算得到的轮速信息更新周期短、精度高,但其无法克服传动系统中由于齿隙所产生的冲击干扰。为充分发挥两种估算模型的优势,本文采用交互多模型融合算法对两个模型的输出结果进行加权融合,并通过实车对比测试,验证了所提出的低速车速估计算法在不同行驶路面下的准确性和可靠性。结果表明,相较于传统轮速估算方法,该方法在低速工况下具有更高的估计精度和实时性。

**关键词:** 低速轮速估计; 多传感器融合; 卡尔曼滤波; 交互多模型融合

## Research on the Estimation of Vehicle Speed Under Low-Speed Conditions Based on Multi-sensor Information

Pu Zhenfeng<sup>1</sup>, Tang Liang<sup>1</sup>, Shangguan Wenbin<sup>2</sup>, Wang Weiwei<sup>3</sup> & Jiang Kaihong<sup>3</sup>

1. School of Technology, Beijing Forestry University, Beijing 100083;  
2. School of Mechanical and Automotive Engineering, South China University of Technology, Guangzhou 510641;  
3. Ningbo Tuopu Group Co., Ltd., Ningbo 315800

**[Abstract]** To solve the problem of low measurement accuracy and long update period of wheel speed sensor under low-speed conditions, a method for estimating low-speed of an electric vehicle is proposed based on multiple sensor signals by using the existing sensors located at chassis. The speed estimation models based on multi-wheel speed pulse signal (model I) and motor speed signal (model II) is established respectively to accurately estimate the vehicle speed. When estimating the wheel speed, model I can effectively avoid noise interference, but its update period is longer at very low speed. In contrast model II estimates the wheel speed information with a short update period and high accuracy, but it can't overcome the impact interference caused by backlash in the drive train. To take into full play of the advantages of the two estimation models, an interactive multi-model fusion algorithm is used in this paper to fuse the output of the two models. The accuracy and reliability of the proposed low-speed estimation algorithm under different roads are validated by actual vehicle comparison experiments. The results show that compared with the traditional algorithm, the proposed method in this paper has higher accuracy and better real-time performance at low-speed conditions.

**Keywords:** wheel low-speed estimation; multi-sensor fusion; Kalman filter; interactive multi-model fusion

<sup>\*</sup> 国家自然科学基金(51975057)资助。

原稿收到日期为2022年12月15日,修改稿收到日期为2023年01月27日。

通信作者:唐亮,教授,博士生导师,E-mail:happyliang@bjfu.edu.cn。

## 前言

随着智能车辆技术的发展,车辆控制的精细化程度越来越高,高精度的车速信息是实现车辆运动控制的基础。在自动泊车功能中,准确实时的轮速和车速信息可提高车辆位姿估算的准确性<sup>[1-2]</sup>,实现精准地泊车和减少控制时的超调冲击。然而,受限于泊车系统硬件电子元件的特性和执行机构的性能,泊车算法会限制最高车速。泊车最高车速一般为10 km/h。在泊车过程中,车速经常会低于5 km/h。由于车速过低,轮速传感器发出的脉冲信号间隔时间增长,轮速信号的准确性和实时性大大下降,这会导致车辆位姿估算的精度下降。多普勒雷达、五轮仪等可直接精确测量车速,但是由于成本限制和结构布置等因素,此类设备无法应用于量产汽车。但是随着低速场景下控制需求的增加,利用标准车载传感器进行低速车速估算的需求也在日益增加。

目前车速估计的方法主要有两种。一种是利用轮速传感器信号和惯性测量单元(IMU)信号设计车速估计器,同时利用全球定位系统(GPS)的数据进行校正。但是常规GPS精度低,传感器信号受环境因素影响大,常出现信号丢失的情况,其可靠性难以满足控制系统的需求<sup>[3-4]</sup>。Ding等<sup>[5]</sup>利用全球定位系统、惯性测量单元以及轮毂电机状态信息,设计了面向四轮独立驱动车辆的纵向车速估计算法。另一种是通过传感器信息和建立的车辆动力学模型,设计状态观测器,估算车速。该方法的准确性与所建立的车辆动力学模型密切相关<sup>[6]</sup>。国内外诸多学者对轮速信号的噪声以及车速估计做了广泛的研究工作。在消除轮速信号的周期性噪声方面,为解决齿圈的非理想等间距所产生的周期性噪声,基于齿圈几何模型和递推约束最小二乘估计算法,Rallo等<sup>[7]</sup>提出了一种在线滤波方法,试验证明了该滤波算法不会消除系统本身的速度波动特征信息。对高速行驶时轮速传感器的信噪比降低以及由轮速信号计算数据的发散性等问题,韩宗奇等<sup>[8]</sup>提出先将轮速信号在频域中进行“滤波”,再通过傅里叶逆变换获得时域下的真实信号。

在基于运动学和动力学的车速估计研究方面,陈浩等<sup>[9]</sup>利用1阶扩张状态观测器,将车辆纵向动力学方程中的未知非线性部分作为扩张状态进行估计,降低了模型精度对车速估计的影响。Karlsson

等<sup>[10]</sup>以加速度计和陀螺仪测量值为输入,提出了一种基于深度学习卷积神经网络(CNN)的车速估算方法。高振海等<sup>[11]</sup>基于车辆动力学模型,提出了一种以底盘域传感器信息为输入、基于混合神经网络架构的车速估计算法。Hashemi等<sup>[12]</sup>基于卡尔曼滤波器,将LuGre轮胎模型和车辆动力学相结合,提出了一种车辆纵向车速估计方法。在大加速度工况下,由于车辆模型和轮胎模型会具有很强的非线性,此时经典的卡尔曼滤波器将不再适用,文献[13]~文献[15]中将适用于非线性系统的扩展卡尔曼滤波器和无迹卡尔曼滤波器应用到车速估计中。为避免滤波发散,提高估计精度,周卫琪等<sup>[16-17]</sup>提出利用最小偏度单形采样策略和遗传算法改进无迹卡尔曼滤波器来减小噪声干扰对车辆状态估计精度的影响。

近年来,随着分布式驱动电动汽车控制技术的发展,针对全轮驱动的分布式驱动电动汽车的纵向车速估计方法已经成为车辆动力学领域的热点问题。高博麟等<sup>[18]</sup>利用分布式驱动电动汽车的优势设计了基于联邦卡尔曼滤波技术的多方法融合的车速估计方法。赵治国等<sup>[19]</sup>针对分布式驱动混合动力汽车,利用其后轮毂电机转矩可测和前轮驱动转矩可推算的特点,设计了对噪声方差及均值具有自适应功能的无迹卡尔曼车速估计算法。余卓平等<sup>[20]</sup>融合运动学和动力学纵向车速估计方法,利用加速度传感器信息和各车轮滑移率反馈值提出了一种纵向车速非线性自适应估计算法。

然而,针对车辆在极低速工况下的车速估计研究则相对较少。目前,用于确定车轮角速度的多是增量编码器类型的传感器<sup>[7]</sup>,均是以脉冲数为基础计算轮速。当轮速极低时,每单位时间的脉冲数较低甚至为零,除非检测到脉冲,否则无法更新轮速信息。Pino等<sup>[21]</sup>采用增加霍尔传感器的采样时间以及使用特殊化后的卡尔曼滤波器方法,以减小在低速工况下轮速传感器的量化噪声。中高速工况下的车速估计研究主要是为解决当车轮滑移和侧偏时,车速无法直接通过轮速进行简单计算得到的问题,而低速工况下的车速估计研究主要解决低速工况下,轮速信号精度变低、更新周期变长等因素对车速估算的影响。

综上所述,目前对车速估计算法的研究主要集中在轮速信号的噪声处理以及中高速工况下的车速估算上,关于极低速工况下的车速估计研究较少。为提高低速下车速估算的实时性和准确性,本文针

对电驱动汽车提出了一种基于多传感器信息的低速车速估计方法:建立了基于自适应加权融合的轮速算法,提高轮速信息的更新频率;利用电驱动汽车传动系统简单的特点,提出基于电机转速信号的车速估计模型;通过交互多模型融合算法将基于轮速脉冲信号的估计车速和基于电机转速的估计车速进行加权融合,提高车速估计的精度。

## 1 基于多传感器信息融合的低速车速估计算法

### 1.1 算法框架

传感器输入的信号有:4个轮速传感器提供4个车轮的轮速脉冲信号 $I_i, i \in \{fl, fr, rl, rr\}$ ,转向盘角度传感器提供转向盘转角信号 $\delta$ ,惯性测量单元提供车辆纵向加速度 $a_{xIMU}$ 、侧向加速度 $a_{yIMU}$ 和车辆横摆角速度信号 $\omega_{rIMU}$ ,驱动电机的旋转变压器提供驱动电机的转速信号 $n_f, n_r$ 。

基于测量的信号,建立两个车速估算模型I(基于多轮速脉冲信号的车速估算模型)和模型II(基于电机转速信号的车速估算模型)。

(1)模型I的估算方法。首先根据转向盘转角 $\delta$ 判断车辆处于直行或是转弯工况。如果是直行工况,则根据各轮速脉冲信号的跳变时刻,将4个车轮的轮速进行加权融合计算得到更新周期更短的轮速信息。如果是转弯工况,则利用阿克曼转向定理,通过轮速换算以缩短轮速信息的更新周期。最后,基于车辆运动学,利用缩短更新周期后的轮速信息和车辆横摆角速度计算车辆质心处的纵向车速和侧向车速。

(2)模型II的估算方法。首先根据电机转速信号 $n_f, n_r$ 和转向盘转角信号 $\delta$ ,利用整车传动模型计算轮速,再根据车辆运动学模型计算车辆质心处的纵向车速和侧向车速。

(3)基于模型I估算车速时,可有效地避免噪声干扰,基于模型II估算车速时,求得的车速信息更新周期短、精度高。采用交互多模型融合估计算法(IMM)对两个子模型的估计结果进行加权融合,将两个模型的优势融合到一个组合过滤器中,最终得到较为理想的车速估计结果。

### 1.2 基于多轮速脉冲信号的车速估算模型(模型I)

#### 1.2.1 轮速计算

霍尔式轮速传感器由齿圈和霍尔传感器组

成<sup>[19]</sup>,霍尔传感器固定在支架上,齿圈随车轮一起转动,在齿圈齿尖靠近或远离霍尔传感器的过程中,传感器内的霍尔元件产生随磁场强度变化的霍尔电压,经电路处理后霍尔传感器输出频率与轮速呈比例的脉冲信号。

工程中常用式(1)计算轮速 $V[k]$ :

$$V[k] = \frac{N[k-1]}{T_N[k-1]} \cdot \frac{2 \cdot \pi \cdot R_0}{N_z} \quad (1)$$

式中: $V[k]$ 为第 $k$ 个周期时计算的轮速; $N_z$ 为齿圈齿数; $R_0$ 为轮胎有效滚动半径; $T_N[k-1]$ 为 $(k-1)$ 周期的时间长度; $N[k-1]$ 为 $(k-1)$ 周期时轮速传感器脉冲信号的个数。

当车速较高时, $T_N[k-1]$ 的取值为运行周期,固定不变。当车速较低时,单位运行周期 $T_N[k-1]$ 内所能检测到的脉冲数较低或为零,此时由于无法检测到新的脉冲,传统轮速算法会自动切换至周期法,即通过计数器计算一个完整矩形脉冲所经过的时间,并将其赋值给 $T_N[k-1]$ 。这在一定程度上可以提高轮速的计算精度,但同时也会降低轮速的更新频率,其最直观的表现便是轮速曲线中出现非连续的阶梯跳变。

#### 1.2.2 自适应加权轮速算法

为解决单个轮速传感器时轮速更新周期长的问题,本节在传统轮速算法的基础上,通过综合整车4个轮速传感器的轮速脉冲信息,建立自适应加权轮速计算模型。该模型主要面向自动泊车等车辆速度极低且没有大强度的加速或减速的工况,即假设车轮的滑移率均很低可忽略不计。

算法的步骤如下。

(1)利用各轮速脉冲信号 $I_i$ ,根据式(1)通过周期法计算各轮轮速 $V_{wi}$ 。

(2)根据转向盘转角 $\delta$ 判断汽车是转弯还是直行工况。考虑到转向盘的自由行程,设定当转向盘转角的绝对值小于 $10^\circ$ 时,车辆处于直行工况,否则,车辆处于转弯工况。

(3)在直行工况下,根据轮速信号的脉冲更新时间,计算各轮速信号的权值(可信度),通过自适应加权融合得到更新频率更高、实时性更好的轮速。各轮速信号的权值 $\lambda_i$ 的计算公式为

$$\lambda_i = \frac{-\Delta t_{k_i} + \sum_{i=1}^4 \Delta t_{k_i}}{\sum_{i=1}^4 \left( -\Delta t_{k_i} + \sum_{i=1}^4 \Delta t_{k_i} \right)}; \Delta t_{k_i} = T_k - t_i \quad (2)$$

式中 $\Delta t_{k_i}$ 为各轮在当前时刻 $T_k$ 与最近一次出现脉冲



跳变时刻 $t_i$ 之间的时间差,  $\Delta t_{k_i}$ 越小, 表明该轮轮速信号的可信度越高。

由于直线行驶时四轮轮速相差很小, 通过加权系数将4个轮速传感器的数据进行融合得到虚拟车速 $V_1$ , 即

$$V_1 = \sum_{i=1}^4 \lambda_i V_{wi} \quad (3)$$

式中:  $\lambda_i$  为各轮轮速信号的权重系数;  $V_{wi}$  为各轮按周期法求得的轮速。

(4) 在转弯工况下, 根据阿克曼转向原理, 利用已知的转向盘转角 $\delta$ 、转向总传动比 $K$ 、车辆轴距 $l$ 和轮距 $S$ , 计算车辆前外轮转角 $\delta_o$ 和前内轮转角 $\delta_i$ 。然后根据车辆前内外轮转角和轮距, 计算各个车轮的转弯半径, 最后通过轮速映射, 提高轮速信号的更新频率。

前轮转角的计算公式为

$$\begin{cases} \cot \delta_o + \cot \delta_i = 2 \cot \varphi \\ \cot \delta_o = \frac{S}{l} + \cot \delta_i \end{cases} \quad (4)$$

式中 $\varphi$ 为前轮平均转角,  $\varphi = \delta/K$ 。

各个车轮的转弯半径的计算公式为

$$\begin{cases} R_{fi} = \frac{l}{\sin \delta_i} \\ R_{fo} = \frac{l}{\sin \delta_o} \\ R_{ri} = \frac{V_{ri} S}{(V_{ro} - V_{ri})} \\ R_{ro} = R_{ri} + S \end{cases} \quad (5)$$

式中下标fi、fo、ro、ri分别表示前内轮、前外轮、后外轮及后内轮。

当车辆处于大角度转向时, 各个车轮间轮速相差较大, 此时选取 $\Delta t_{k_i}$ 最小的车轮的轮速 $V_{wi}$ 作为虚拟轮速, 通过阿克曼转向模型换算剩余车轮的轮速, 即当车辆在低速工况下转向时, 4个车轮的轮心绕转向中心点所做圆周运动的角速度相等。因此, 各轮轮速间的换算关系为

$$V_a = \frac{R_a}{R_b} V_{wb} \quad (6)$$

式中:  $a, b \in \{fi, fo, ro, ri\}$ , 其中不计算虚拟轮;  $V_a$  为待求轮速;  $V_{wb}$  为虚拟轮速;  $R_a$  和  $R_b$  分别为转向时待求轮和虚拟轮车轮的转弯半径, 具体由式(5)求得。

最后, 根据运动学模型, 通过前轮平均转角 $\varphi$ , 前轮轮速 $V_{fi}$ 、 $V_{fo}$ , 车辆横摆角速度 $\omega_r$ 和车辆质心到前轴距离 $l_f$ 计算车辆质心处的纵向车速 $V_{1x}$ 和侧向车速 $V_{1y}$ :

$$\begin{cases} V_{1x} = \frac{V_{fi} + V_{fo}}{2} \cos \varphi \\ V_{1y} = \frac{V_{fi} + V_{fo}}{2} \sin \varphi - \omega_r l_f \end{cases} \quad (7)$$

### 1.3 基于电机转速信号的车速估算模型(模型II)

目前大部分纯电动汽车采用的是单级固定速比减速器的减速方案, 整车传动系统中取消了离合器或液力变矩器, 这使得通过驱动电机的转速信息进行轮速估计的方法变得更加方便。试验车辆由两个驱动电机分别驱动前后轴。驱动电机与车轮之间通过减速器和差速器传递动力。

当车辆直行时, 前轮和后轮轮速为

$$\begin{cases} V_{fj} = \frac{0.377 \times n_f \times R_0}{i_{of}} \\ V_{rj} = \frac{0.377 \times n_r \times R_0}{i_{or}} \end{cases} \quad (8)$$

式中:  $V_{fj}$ 、 $V_{rj}$  分别为前轮和后轮轮速;  $n_f$ 、 $n_r$  分别为前驱动电机和后驱动电机的转速;  $i_{of}$ 、 $i_{or}$  分别为前后减速器的减速比。在整车VCU及电机控制器MCU的控制下, 根据前后电机转速计算所得的前后轮速相差很小, 因此可只采用前驱动电机的转速信息进行车速计算。

当车辆转弯时, 由于差速器的作用, 左右两侧车轮转速 $\omega_{il}$ 、 $\omega_{ir}$ 的平均值等于差速器的输入轴转速:

$$\frac{\omega_{il} + \omega_{ir}}{2} = \frac{n_i}{i_{oi}} \quad (9)$$

将四轮模型转化为两轮自行车模型后, 虚拟前轮轮速 $V_f$ 可由前差速器输入轴转速求得:

$$V_f = \frac{0.377 \times n_i \times R_0}{i_{oi}} \quad (10)$$

车辆质心处的纵向车速 $V_{2x}$ 和侧向车速 $V_{2y}$ 分别为

$$V_{2x} = V_f \cos \varphi; V_{2y} = V_f \sin \varphi - \omega_r l_a \quad (11)$$

### 1.4 基于交互多模型的融合车速估计

基于多轮速传感器脉冲信号的车速估算模型可以有效地避免噪声干扰, 但在极低速的情况下, 其更新周期变长, 而基于电机转速信号的车速估算模型更新周期短, 精度高, 但传动系统中的齿隙以及电机低速时的转速波动导致车速估计结果存在波动。为充分发挥两个估算模型的优势, 本文采用交互多模型融合算法(IMM)对两个车速计算模型的输出结果进行加权融合。交互多模型算法是一种软切换算法, 能够对每个子模型的加权因子(模型概率)进行实时调整, 从而降低估计误差。完整的算法循环包括输入交互、数据滤波、模型概率更新和输出交互4

部分<sup>[22]</sup>。以纵向车速估计为例,在第 $k$ 时刻,完整的计算步骤如下。

#### 步骤1:输入交互

将上一时刻( $k-1$ 时刻)数据滤波步骤中模型I和模型II的卡尔曼滤波器输出的状态估计值 $\hat{X}_i(k-1|k-1)$ 、误差协方差 $P_i(k-1|k-1)$ ,通过模型混合概率 $\mu_{ij}(k-1|k-1)$ 进行加权融合,并将其作为当前时刻步骤2中卡尔曼滤波器的状态初值 $\hat{X}_{0i}(k-1|k-1)$ 和初始误差协方差 $P_{0i}(k-1|k-1)$ ,其中 $i, j$ 为模型序列。本文因只采用了两个模型,故取 $i, j = 1, 2$ 。由模型 $i$ 到模型 $j$ 的混合概率 $\mu_{ij}(k-1|k-1)$ 的计算公式为

$$\mu_{ij}(k-1|k-1) = p_{ij}\mu_i(k-1)/\bar{c}_j \quad (12)$$

其中 $\bar{c}_j = \sum_{i=1}^2 p_{ij}\mu_i(k-1)$

式中: $\mu_i(k-1)$ 为上一时刻在模型概率更新步骤中求得的各模型的模型概率; $\bar{c}_j$ 为各模型的归一化常数; $p$ 为马尔科夫概率转移矩阵,矩阵元素 $p_{ij}$ 决定了输入交互的作用程度,考虑系统的稳定性和准确性,最终, $p$ 取为

$$p = \begin{bmatrix} p_{11} & p_{12} \\ p_{21} & p_{22} \end{bmatrix} = \begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix} \quad (13)$$

若为第一次循环( $k=1$ ),则模型概率 $\mu_i(k-1)$ 、状态估计值 $\hat{X}_i(k-1|k-1)$ 和误差协方差 $P_{0i}(k-1|k-1)$ 均取初值:

$$\begin{cases} \mu_i(0) = \mu_j(0) = 0.5 \\ \hat{X}_i(0|0) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}; P_i(0|0) = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \end{cases} \quad (14)$$

#### 步骤2:数据滤波

利用卡尔曼滤波器分别对两个车速估算模型进行数据滤波。

模型I的卡尔曼滤波器:利用惯性测量单元的纵向加速度信号 $a_{xIMU}$ 与由模型I计算所得的纵向车速信号 $V_{1x}$ 通过卡尔曼滤波器进行滤波。考虑道路坡度对纵向加速度信号的影响,实际的车辆纵向加速度 $\dot{v}_x$ 为

$$\dot{v}_x = a_{xIMU} - g \cdot i \quad (15)$$

式中: $g$ 为重力加速度; $i$ 为道路坡度,实际行驶过程中坡度变化缓慢,可以认为道路坡度 $i$ 对时间的导数为零。因此,可建立微分方程组:

$$\begin{cases} \dot{v}_x = a_{xIMU} - g \cdot i \\ \dot{i} = 0 \end{cases} \quad (16)$$

将其离散化,得到:

$$\begin{cases} v_x(k) = v_x(k-1) + a_{xIMU}(k) \cdot \Delta t - \\ \quad g \cdot i(k-1) \cdot \Delta t \\ i(k) = i(k-1) \end{cases} \quad (17)$$

式中 $\Delta t$ 为程序运行周期。

将纵向车速 $v_x$ 和道路坡度 $i$ 作为状态变量,将式(17)转化为状态空间方程的形式:

$$\begin{cases} \mathbf{x}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{B}u_k + w_k \\ z_k = \mathbf{H}\mathbf{x}_k + v_k \end{cases} \quad (18)$$

其中: $\mathbf{x}_k = \begin{bmatrix} v_x \\ i \end{bmatrix}$ ;  $z_k = V_{1x}$ ;  $u_k = a_{xIMU}$

式中: $\mathbf{x}_k$ 为状态变量; $z_k$ 为系统测量值; $u_k$ 为系统输入; $w_k$ 为系统过程噪声; $v_k$ 为测量噪声,它们是均值为零且相互独立的高斯白噪声,各自的协方差矩阵分别为 $\mathbf{Q}$ 、 $\mathbf{R}$ ;系统矩阵 $\mathbf{A}$ 、控制矩阵 $\mathbf{B}$ 和观测矩阵 $\mathbf{H}$ 分别为

$$\mathbf{A} = \begin{bmatrix} 1 & -g \cdot \Delta t \\ 0 & 1 \end{bmatrix}; \mathbf{B} = \begin{bmatrix} \Delta t \\ 0 \end{bmatrix}; \mathbf{H} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad (19)$$

卡尔曼滤波器主要包含时间更新和测量更新两个过程<sup>[19]</sup>。

(1)时间更新:获得先验状态估计值 $\hat{\mathbf{x}}_{k|k-1}$ 和先验估计协方差 $\mathbf{P}_{k|k-1}$ 。

(2)测量更新:首先计算卡尔曼增益,再根据卡尔曼增益和测量值计算最优的状态估计值 $\hat{\mathbf{x}}_{k|k}$ 以及误差协方差 $\mathbf{P}_{k|k}$ ,其中 $\hat{\mathbf{x}}_{k|k}$ 即为模型I中纵向车速和坡度的最优状态估计 $\hat{X}_1(k|k)$ 。

模型II的卡尔曼滤波器:将基于电机转速信号的车速估算模型(模型II)求得的纵向车速 $V_{2x}$ 作为卡尔曼滤波器的测量值 $z_k$ ;将 $a_{xIMU}$ 作为卡尔曼滤波器的系统输入 $u_k$ ;系统矩阵、控制矩阵和观测矩阵均与模型I中的对应矩阵相同。经时间更新和测量更新后得到模型II中纵向车速和道路坡度的最优状态估计 $\hat{X}_2(k|k)$ 和误差协方差 $\mathbf{P}_2(k|k)$ 。

#### 步骤3:模型概率更新

交互多模型算法最终是将步骤2中两个滤波器的状态估计结果进行加权融合。利用极大似然函数 $\Lambda_i(k)$ 计算每个模型的模型概率 $\mu_i(k)$ :

$$\begin{cases} \mu_i(k) = \Lambda_i(k)\bar{c}_i/c; c = \sum_{i=1}^2 \Lambda_i(k)\bar{c}_i \\ \Lambda_i(k) = \frac{\exp\{-\mathbf{v}_i^T \mathbf{S}_i^{-1}(k) \mathbf{v}_i/2\}}{(2\pi)^{n/2} |\mathbf{S}_i(k)|^{1/2}} \end{cases} \quad (20)$$

其中:

$$\begin{cases} \mathbf{v}_i(k) = z(k) - \mathbf{H}(k)\hat{\mathbf{X}}_i(k|k-1) \\ \mathbf{S}_i(k) = \mathbf{H}(k)\mathbf{P}_i(k|k-1)\mathbf{H}(k)^T + \mathbf{R} \end{cases} \quad (21)$$

#### 步骤4:输出交互

将步骤2中得到的两个模型的卡尔曼滤波器的状态估计结果 $\hat{X}_i(k|k)$ ,通过步骤3中得到的模型概率 $\mu_i(k)$ 进行加权融合,得到最终的估计值 $\hat{X}(k|k)$ :

$$\hat{X}(k|k) = \sum_{i=1}^2 \hat{X}_i(k|k) \mu_i(k) \quad (22)$$

式中 $\hat{X}(k|k)$ 即为最终输出的纵向车速的估计结果 $V_{x\text{IMM}}$ 。

侧向车速也采用交互多模型融合估计方法,具体步骤和纵向车速估计相似,不同的是在数据滤波步骤中,采用一维卡尔曼滤波器将模型 $i$ 得到的 $V_{iy}$ 与加速度信号 $a_{y\text{IMU}}$ 进行融合滤波。设置滤波器的状态变量为 $v_y$ ,系统输入为 $a_{y\text{IMU}}$ ,观测值为 $V_{iy}$ 。系统矩阵 $A$ 和观测矩阵 $H$ 均设为1,控制矩阵 $B$ 的取值设为 $\Delta t$ 。经交互多模型融合估计后得到侧向车速的估计结果 $V_{y\text{IMM}}$ 。最终估计得到的车辆合速度 $V_{\text{IMM}}$ 为

$$V_{\text{IMM}} = \sqrt{V_{x\text{IMM}}^2 + V_{y\text{IMM}}^2} \quad (23)$$

## 2 车速估计算法的验证

### 2.1 试验场地及试验设备

为检测所提出算法的实时性与有效性,本文进行了实车试验。在不同路面上进行低速直行和低速转弯以验证算法的可靠性,试验场景如图1所示,其中测试路面包括平坦路面、鹅卵石路面和坡度为18%的坡道。



(a) 平坦路面 (b) 复杂路面 (c) 坡道

图1 实车试验场景

实车试验平台如图2所示,试验采用一辆双电机四驱SUV作为试验车辆,该车配备有基础的底盘域传感器,即包括轮速传感器、惯性测量单元、转向盘角度传感器、挡位传感器等。其中惯性单元固定在靠近车辆质心,用于测量车辆纵向加速度、侧向加速度以及横摆角速度。同时,该车还装备有VBox数据采集系统(非接触式汽车测试仪),其可通过高精度GPS信号精确地测量车辆的实际速度,用于验证

车速估计算法的准确性。惯性测量单元信号和4个轮速传感器信号通过线束与控制器连接,电机转速信号和转向盘角度信号通过整车CAN网络输出给控制器和数据采集系统。同时,控制器输出的车速估计结果也可通过CAN网络输出,最后利用数据采集系统和计算机采集并记录试验数据。试验车辆详细参数如表1所示。




图2 实车试验平台

表1 车辆结构参数

内容	符号	数值	单位
轴距	$l$	3.11	m
质心至前轴距离	$l_a$	1.586 1	m
质心至后轴距离	$l_b$	1.523 9	m
轮距	$S$	1.69	m
转向传动比	$K$	16.26	
车轮滚动半径	$R_0$	0.374 26	m
前轴主减速器减速比	$i_{0f}$	10.136	
后轴主减速器减速比	$i_{0r}$	9.599	

### 2.2 试验结果

在典型的低速行驶工况下,对所提出的低速车速估计算法进行验证。将VBox所测得的车辆合速度作为用来参考的实际车速,并将传统ESP算法输出的车速估计结果和本文所提出的基于多传感器信息融合的低速车速估计算法输出的车速估计结果进行对比。试验工况包括在平坦路面下的低速直行和低速转弯工况以及在复杂路面和坡道上的低速直行工况。

本文中用于对比的ESP算法采用了一种基于传感器信号融合的级联观测器系统进行车速估计<sup>[23]</sup>。该车速观测器系统由底层、中层和上层组成。底层为低通滤波器,用于滤去传感器的部分噪声,得到转向盘转角、车轮轮速、纵向和侧向加速度以及制动管路压力等信号;中间层基于滤波后的传感器信号估算道路坡度、制动力矩并根据上层估计得到的纵向和侧向车速估算车轮滑移率和侧滑角;上层则进行路面附着系数估计、轮胎力估计、通过车辆动力学估



算车辆的纵向、侧向加速度,通过纵向车速估计器和侧向车速估计器融合轮速及加速度传感器信号得到纵向和侧向车速,并最终获得车辆的合速度。

### 2.2.1 平坦路面下的试验结果

在平坦路面下低速直行试验中,车辆由静止起步。试验结果如图3所示。由图可见:当车辆刚开始起步时,由于采用的是周期法计算轮速,ESP算法输出的车速曲线呈现出明显的阶梯状;而本文中提出的车速估计算法融合了更新周期更短的电机转速信息,在车辆起步阶段可以得到更加准确实时的车速估计结果。

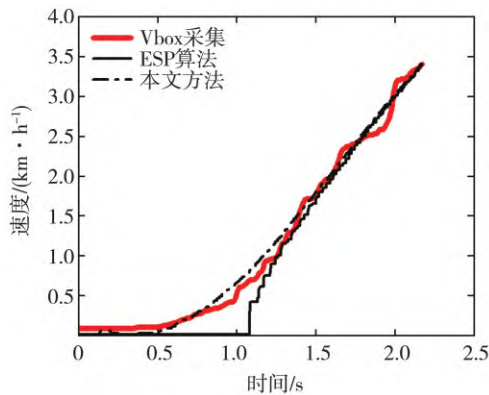


图3 平坦路面下低速直行试验结果

在平坦路面下低速转弯试验中,车辆由静止起步,驾驶员施加的转向盘转角曲线如图4所示,向左转向时转向盘转角为负,向右转向时转向盘转角为正。速度曲线如图5所示。在8s左右时车辆开始减速,此时由于检测不到新的轮速脉冲,传统ESP算法的车速曲线会出现短暂的延迟,而本文提出的算法的车速曲线能够快速跟踪实际车速的变化。但是,在4和9s左右,当转向盘转角最大时,估算的车速与实际车速间出现较大的误差。这是由于实际车辆转向系统的非线性特性,即实际的转向总传动比 $K$ 并非恒定值,由转向盘转角计算前轮转角时出现误差,导致车速估算结果出现偏差。

### 2.2.2 复杂路面下的试验结果

在复杂路面下的低速直行工况试验中,选用鹅卵石路面作为复杂路面,试验结果如图6所示。同其他试验工况类似,起步时,ESP输出的车速曲线存在较大的延迟,并且由于路面颠簸,车速曲线出现较大波动。得益于卡尔曼滤波器的滤波作用,本文提出的算法的车速曲线波动较小,输出的车速曲线相对更加平稳。但是由于并未考虑车辆在颠簸路面上




图4 转向盘转角曲线

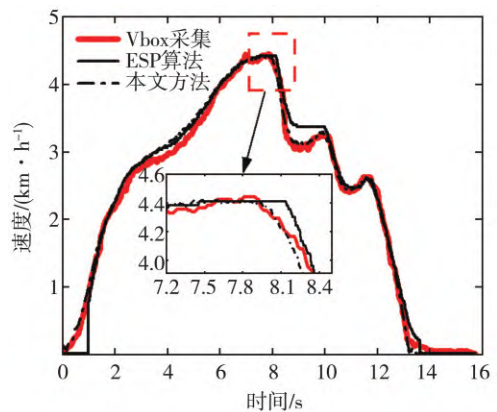


图5 平坦路面下低速转弯试验结果

的俯仰和侧倾运动对加速度信号的影响,故本文方法估算出的车速与实际车速之间仍有一定的偏差。




图6 复杂路面下低速直行

### 2.2.3 坡道上的试验结果

当车辆处于坡道上时,受重力影响,惯性单元所测得的加速度与车辆的实际加速度之间存在偏差,因此,获得道路的坡道对进行车速估计具有重要的

作用。道路坡度的估算结果如图7所示,车速的估计结果如图8所示。




图7 坡度估计结果





图8 坡道上低速直行试验结果

如图8(a)所示,当车速达到0.7 km/h时,ESP算法输出的车速曲线才会出现变化,而本文提出的算法可以实时更新车速变化,其所能检测到的最低车速远小于0.7 km/h。图8(b)为模型I、模型II以及本

文利用融合算法将两个模型加权融合最终输出的车速结果对比。低速工况下,由于驱动电机转速信号的波动,模型II输出的车速估计曲线也呈现出一定的波动。基于轮速脉冲信号的模型I的车速估计结果则不存在这种波动噪声,但是其更新周期长,存在阶梯形的量化噪声。本文提出的车速估计算法将两个模型的估计结果加权融合,在缩短车速更新周期的同时减小了电机转速信号的波动噪声对车速估计的影响,最终得到更加精准的车速估计结果。由于当车辆处于坡道上时,难以使车辆保持在相对恒定的低速状态,故车速曲线波动较大,同时加速度信号受车辆俯仰的影响也变大,导致坡度估算出现一定的偏差,车速估算结果也受到一定的影响。

为了将本文提出的算法和传统ESP算法的估计精度进行定量比较,分别计算两种算法所输出的车速结果相对于VBox测量值的平均绝对误差(MAE) $s$ :

$$s = \frac{1}{n} \sum_{i=1}^n |x_i - m(x)|, m(x) = \frac{1}{n} \sum_{i=1}^n x_i, x_i = \bar{y}_i - y_i \quad (24)$$

式中: $y_i$ 为由VBox所得的测量值; $\bar{y}_i$ 为算法输出的估计值; $n$ 为在一次实车测试中数据采样点的个数。表2列出了在不同测试场景下,传统ESP算法和本文提出的算法所输出车速信息的MAE指标。

表2 ESP和本文算法所输出车速信息的MAE指标

测试场景	ESP	模型I	模型II	本文算法
平坦路面直行	0.114 5	0.100 1	0.094 3	0.084 8
平坦路面转弯	0.084 9	0.084 0	0.079 7	0.069 8
复杂路面直行	0.197 5	0.150 3	0.139 4	0.020 7
坡道直行	0.048 2	0.047 5	0.048 7	0.038 4

由表2可以看出,采用融合算法后的估计结果比单一方法的估计结果精度更高,并且本文提出的算法的车速估计结果在各种不同测试场景下的MAE指标均比传统ESP算法有所提升,这表明该算法在典型的低速场景下可以得到更加精确稳定的车速估计结果。

### 3 结论

针对电驱动汽车,本文以低速工况下的车速估计方法为研究对象,利用轮速传感器脉冲信号和电机转速信号建立了两个车速子估计器模型,通过交互多模型融合算法充分发挥两个子估计器模型各自



的优势。通过实车试验得出以下结论:

(1)引入驱动电机的转速信号进行车速估算可以降低低速工况下由轮速传感器的增量式传感器特性所产生的阶梯形量化噪声,并且可以大大降低车辆起步时为等待轮速脉冲所产生的车速更新延迟。

(2)针对驱动电机的转速信号在低速工况下出现波动对车速估计产生影响的问题,将基于多轮速脉冲信号的车速估算模型与基于电机转速信号的车速估算模型的计算结果进行加权融合,由此减小电机转速信号波动和轮速脉冲信号更新周期长对车速估计精度的影响,从而实现更加精确实时的低速车速估计。

对于通过离合器或液力变矩器进行切断和传递动力的传统集中动力式车辆,当车辆处于低速时,离合器或液力变矩器常处于未完全接合状态,此时无法准确地通过动力源(发动机)转速估算轮速,本文中模型II的估计精度将会因此下降,导致最终融合估计结果的精度降低。后续将讨论采用无级变速系统(CVT)的车辆在低速工况下的车速估计方法。

### 参考文献

- [1] SABET M T, DANIALI H R M, FATHI A R, et al. Experimental analysis of a low-cost dead reckoning navigation system for a land vehicle using a robust AHRS[J]. *Robotics and Autonomous Systems*, 2017, 95: 37-51.
- [2] LIU H, LUO S, LU J. Method for adaptive robust four-wheel localization and application in automatic parking systems[J]. *IEEE Sensors Journal*, 2019, 19(22): 10644-10653.
- [3] SCHOLTE W J, MARCO V R, NIJMEIJER H. Experimental validation of vehicle velocity, attitude and IMU bias estimation[J]. *IFAC-PapersOnLine*, 2019, 52(8): 118-123.
- [4] 王震坡,丁晓林,张雷.四轮轮毂电机驱动电动汽车驱动防滑控制关键技术综述[J]. *机械工程学报*, 2019, 55(12): 99-120.  
WANG Z P, DING X L, ZHANG L. Overview on key technologies of acceleration slip regulation for four-wheel-independently-actuated electric vehicles[J]. *Journal of Mechanical Engineering*, 2019, 55(12): 99-120.
- [5] DING X, WANG Z, ZHANG L, et al. Longitudinal vehicle speed estimation for four-wheel-independently-actuated electric vehicles based on multi-sensor fusion[J]. *IEEE Transactions on Vehicular Technology*, 2020, 69(11): 12797-12806.
- [6] 郭洪艳,陈虹,赵海艳,等.汽车行驶状态参数估计研究进展与展望[J]. *控制理论与应用*, 2013, 30(6): 661-672.  
GUO H Y, CHEN H, ZHAO H Y, et al. State and parameter estimation for running vehicle: recent developments and perspective[J]. *Control Theory & Applications*, 2013, 30(6): 661-672.
- [7] RALLO G, FORMENTIN S, SAVARESI S M. On-line model-based wheel speed filtering for geometrical error compensation[J]. *Mechatronics*, 2018, 50: 189-195.
- [8] 韩宗奇,王立强,王瑞林,等.汽车高速行驶时轮速信号时频域变换处理方法[J]. *机械工程学报*, 2014, 50(16): 155-161.  
HAN Z Q, WANG L Q, WANG R L, et al. FFT / IFFT method for wheel speed sensor signal processing when car runs at high speed[J]. *Journal of Mechanical Engineering*, 2014, 50(16): 155-161.
- [9] 陈浩,袁良信,孙涛,等.电动轮汽车车速与道路坡度估计[J]. *汽车工程*, 2020, 42(2): 199-205, 256.  
CHEN H, YUAN L X, SUN T, et al. Estimation of in-wheel motor driven electric vehicle speed and road gradient[J]. *Automotive Engineering*, 2020, 42(2): 199-205, 256.
- [10] KARLSSON R, HENDEBY G. Speed estimation from vibrations using a deep learning cnn approach[J]. *IEEE Sensors Letters*, 2021, 5(3): 1-4.
- [11] 高振海,温文昊,唐明弘,等.基于混合神经网络的汽车运动状态估计[J]. *汽车工程*, 2022, 44(10): 1527-1536.  
GAO Z H, WEN W H, TANG M H, et al. Estimation of vehicle motion state based on hybrid neural network[J]. *Automotive Engineering*, 2022, 44(10): 1527-1536.
- [12] HASHEMI E, KASAEZADEH A, KHOSRAVANI S, et al. Estimation of longitudinal speed robust to road conditions for ground vehicles[J]. *Vehicle System Dynamics*, 2016, 54(8): 1120-1146.
- [13] ZHAO Z, CHEN H, YANG J, et al. Estimation of the vehicle speed in the driving mode for a hybrid electric car based on an unscented Kalman filter[J]. *Proceedings of the Institution of Mechanical Engineers, Part D: Journal of automobile engineering*, 2015, 229(4): 437-456.
- [14] 芦冰,解小华,蔡可天,等. UKF 车速估计器的算法研究与仿真[J]. *吉林大学学报(信息科学版)*, 2015, 33(1): 7-11.  
LU B, XIE X H, CAI K, et al. Speed estimation research and simulation based on UKF algorithm[J]. *Journal of Jilin University (Information Science Edition)*, 2015, 33(1): 7-11.
- [15] 任彦君,殷国栋,沙文瀚,等.基于运动学信息融合的四轮驱动汽车纵向车速自适应估计方法[J]. *机械工程学报*, 2021, 57(8): 184-194.  
REN Y J, YIN G D, SHA W H, et al. Longitudinal velocity adaptive estimation for four-wheel-drive vehicles via kinematic information fusion[J]. *Journal of Mechanical Engineering*, 2021, 57(8): 184-194.
- [16] 周卫琪,齐翔.基于多传感器信息融合的汽车行驶状态估计[J]. *汽车工程*, 2019, 41(1): 7-13, 20.  
ZHOU W Q, QI X. State estimation of vehicle based on multi-sensors information fusion[J]. *Automotive Engineering*, 2019, 41(1): 7-13, 20.

(下转第 1275 页)

- Technology, 2011, 35(5): 510-515.
- [22] 金一, 柳进, 甄彤, 等. 底盘控制臂用800MPa级高强度钢的疲劳特性研究[J]. 上海金属, 2021, 43(6): 47-51.  
JIN Y, LIU J, ZHEN T, et al. Research on fatigue behavior of 800MPa grade high strength steel used for chassis control arm[J]. Shanghai Metals, 2021, 43(6): 47-51.
- [23] 张海阳, 金一, 张梅. 异种铝合金角接头低周疲劳特性试验研究[J]. 上海金属, 2020, 42(5): 27-31.  
ZHANG H Y, JIN Y, ZHANG M. Experimental study on low cycle fatigue characteristics of T-joint of dissimilar aluminum alloy [J]. Shanghai Metals, 2020, 42(5): 27-31.
- [24] 车欣, 梁兴奎, 陈丽丽, 等. Al-9.0%Si-4.0%Cu-0.4%Mg (-0.3%Sc)合金的显微组织及其低周疲劳行为[J]. 金属学报, 2014, 50(9): 1046-1054.  
CHE X, LIANG X K, CHEN L L, et al. Microstructure and low-cycle fatigue behavior of Al-9.0%Si-4.0%Cu-0.4%Mg (-0.3%Sc) alloy [J]. ACTA Metallurgica Sinica, 2014, 50(9): 1046-1054.
- [25] 车欣, 徐志军, 陈立佳, 等. Al-Si-Cu-Mg (-Er)铸造铝合金的低周疲劳行为[J]. 铸造, 2011, 60(1): 20-23.  
CHE X, XU Z J, CHEN L J, et al. Low-cycle fatigue behavior of cast Al-Si-Cu-Mg (-Er) aluminum alloy [J]. Foundry, 2011, 60(1): 20-23
- [26] 荣兵, 肖攀, 周建文. 基于实测载荷谱和仿真载荷谱的底盘疲劳分析及对比[J]. 振动与冲击, 2018, 37(12): 179-186.  
RONG B, XIAO P, ZHOU J W. A fatigue comparative analysis of chassis based on simulated road load spectrum and measured road load spectrum [J]. Journal of Vibration and Shock, 2018, 37(12): 179-186.
- [27] 范璐, 陈伟波, 刘立刚. 基于虚拟载荷的悬架台架耐久试验方法[J]. 汽车工程, 2019, 41(9): 1080-1087.  
FAN L, CHEN W B, LIU L G. A bench test method for suspension durability based on virtual load [J]. Automotive Engineering, 2019, 41(9): 1080-1087.
- [28] TASCI M, TEBBE J, DAVIS J. Development of 3-D digital proving ground profiles for use in virtual prediction of vehicle system/sub-system loads [C]. SAE Paper 2011-01-0189.
- [29] SCHUDT J, KODALI R, SHAH M. Virtual road load data acquisition in practice at general motors [C]. SAE Paper 2011-01-0025.
- [30] 耿动梁, 高丰岭, 卜晓兵, 等. 基于CDTire的车辆动态载荷提取方法[J]. 汽车技术, 2022 (4): 16-22.  
GENG D L, GAO F L, BU X B, et al. Extraction method of vehicle dynamic load based on CDTire [J]. Automobile Technology, 2022 (4): 16-22.
- [31] 方吉, 兆文忠, 朴明伟. 基于模态叠加法的焊接结构疲劳寿命预测方法研究[J]. 振动与冲击, 2015, 34(5): 186-192.  
FANG J, ZHAO W Z, PU M W. Fatigue life prediction of welded structures based on modal superposition method [J]. Journal of Vibration and Shock, 2015, 34(5): 186-192.
- [32] 宋庆伟, 张晶, 王晗. 基于模态应力的转向架关键悬挂件振动疲劳分析[J]. 机车电传动, 2018 (5): 42-45.  
SONG Q W, ZHANG J, WANG H. Vibration fatigue of key suspension parts of bogies based on modal stress [J]. Electric Drive for Locomotives, 2018 (5): 42-45.
- [33] 王玮, 周肖飞. 基于模态应力法的副车架疲劳分析研究[J]. 机械制造与自动化, 2020 (3): 127-129.  
WANG W, ZHOU X F. Subframe fatigue analysis based on modal coordinate [J]. Machine Building & Automation, 2020 (3): 127-129.
- [34] 黄力平. 汽车结构的耐久性—理论与实践[M]. 北京: 机械工业出版社, 2020.  
HUANG L P. Automotive structure durability—principle and practice [M]. Beijing: China Machine Press, 2020.
- ~~~~~
- (上接第1243页)
- [17] 周卫琪, 齐翔, 陈龙, 等. 基于无迹卡尔曼滤波与遗传算法相结合的车辆状态估计[J]. 汽车工程, 2019, 41(2): 198-205.  
ZHOU W Q, QI X, CHEN L, et al. Vehicle state estimation based on the combination of unscented Kalman filtering and genetic algorithm [J]. Automotive Engineering, 2019, 41(2): 198-205.
- [18] 高博麟, 陈慧, 谢书港, 等. 分布式电驱动车车速及路面附着系数融合估计[J]. 汽车工程, 2016, 38(2): 216-220.  
GAO B L, CHEN H, XIE S G, et al. Velocity and road friction coefficient fusion estimation of distributed electric drive vehicle [J]. Automotive Engineering, 2016, 38(2): 216-220.
- [19] 赵治国, 朱强, 周良杰, 等. 分布式驱动HEV自适应无迹卡尔曼车速估计[J]. 中国科学: 技术科学, 2016, 46(5): 481-492.  
ZHAO Z G, ZHU Q, ZHOU L J, et al. Vehicle speed estimation in driving case based on distributed self-adaptive unscented Kalman filter for 4WD hybrid electric car [J]. Sci Sin Tech, 2016, 46(5): 481-492.
- [20] 余卓平, 夏新, 熊璐, 等. 分布式驱动电动汽车纵向车速非线性自适应估计[J]. 同济大学学报(自然科学版), 2016, 44(5): 779-786.  
YU Z P, XIA X, XIONG L, et al. Vehicle longitudinal velocity nonlinear adaptive estimation of distributed drive electric vehicle [J]. Journal of Tongji University (Natural Science), 2016, 44(5): 779-786.
- [21] DEL PINO I, MUNOZ-BANÓN M A, CONTRERAS M A, et al. Speed estimation for control of an unmanned ground vehicle using extremely low resolution sensors [C]. ICINCO (1). 2018: 216-223.
- [22] PING X, CHENG S, YUE W, et al. Adaptive estimations of tyre-road friction coefficient and body's sideslip angle based on strong tracking and interactive multiple model theories [J]. Proceedings of the Institution of Mechanical Engineers Part D: Journal of Automobile Engineering, 2020, 234(14): 3224-3238.
- [23] LI L, SONG J, KONG L, et al. Vehicle velocity estimation for real-time dynamic stability control [J]. International Journal of Automotive Technology, 2009, 10(6): 675-685.